

4. Configuração Experimental

Avaliamos um único LLM multimodal — o **Gemma 4 26B-A4B-it** [1], um modelo Mixture-of-Experts (MoE) com 25,2 bilhões de parâmetros totais e 3,8 bilhões ativos por token, quantizado para 4 bits via AWQ [2] — contra baselines tradicionais específicos de tarefa em dois benchmarks complementares de computação afetiva. O modelo é servido por meio do vLLM [3] em uma única GPU NVIDIA L4 de 24 GB, expondo uma API compatível com o padrão OpenAI. A orquestração da inferência é realizada via LangGraph [4], com parsing manual de JSON e validação por Pydantic (temperatura = 0, máximo de 512 tokens).

4.1 Bases de Dados

O **OMG-Empathy** [5] fornece 80 vídeos de interações diádicas (~7 h), nos quais um ouvinte reage a histórias emocionais contadas por um ator. Após cada sessão, o ouvinte anotou continuamente seu estado afetivo em uma escala de valência (−1 a +1) por meio de joystick. Utilizamos o split oficial de teste (histórias 3, 6 e 7; 15 vídeos de 10 sujeitos) e avaliamos por meio do Concordance Correlation Coefficient (CCC) [6], calculado por série temporal de cada vídeo, seguindo o protocolo do challenge.

O **CMU-MOSEI** [7] contém aproximadamente 23.000 segmentos anotados de vídeos do YouTube, com intensidades das seis emoções básicas de Ekman (0–3) [8]. As features pré-extraídas são acessadas no formato do CMU Multimodal SDK [9]: transcrições do arquivo `TimestampedWords.csd` e features visuais FACET [10] de 35 dimensões do arquivo `VisualFacet42.csd`. A avaliação é realizada em 400 segmentos de teste com F1-score multi-rótulo (micro, macro e ponderado), tratando cada emoção como presente quando sua intensidade excede zero.

4.2 Condições Experimentais

Definimos três condições de entrada para o LLM, variando a modalidade do sinal apresentado no prompt, conforme apresentado na **Tabela I**.

Tabela I. Condições de entrada do LLM por modalidade e dataset.

Condição	Entrada para o LLM	Disponível em
C1 — Texto	Transcrição verbatim do falante	Apenas MOSEI
C2 — Features faciais como texto	Estatísticas de blendshapes (OMG) ou coeficientes FACET (MOSEI) serializados	Ambos
C3 — Visão nativa	3 keyframes JPEG por janela de 4 s, codificados em base64	Apenas OMG

Para o OMG, as features faciais são extraídas com o MediaPipe Face Landmarker [11]: 8 frames uniformemente amostrados por janela de 4 s, agregados em média, máximo e desvio-padrão dos 15 coeficientes de blendshape mais ativos dentre os 52 disponíveis. Para o MOSEI, as features FACET são promediadas temporalmente dentro do intervalo de cada segmento.

Variantes zero-shot e few-shot (aprendizado in-context) são avaliadas. Os exemplos few-shot são extraídos exclusivamente do split de treino para evitar vazamento de dados.

4.3 Baselines

Para o OMG-Empathy, o baseline consiste no módulo rule-based `face_blendshape`, que mapeia os 52 coeficientes de blendshape para valores de valência e arousal por meio de regras manuais, fundamentadas no modelo circumplexo do afeto [12]. Agregação multi-frame (média + pico) é aplicada para corresponder à janela temporal do LLM.

Para o CMU-MOSEI, o baseline é um classificador de Regressão Logística multi-saída, treinado em 6.000 segmentos de features FACET, predizendo seis rótulos binários de emoção independentes. Reportamos também um baseline de acaso aleatório (amostragem proporcional à prevalência de classe) e um baseline majoritário (sempre predizendo *happiness*).

5. Resultados

5.1 OMG-Empathy: Regressão Contínua de Valência

A **Tabela II** reporta o CCC médio entre os 15 vídeos de teste (janelas de 4 s, avaliação por série temporal de cada vídeo). Intervalos de confiança bootstrap de 95% (10.000 reamostragens) são fornecidos juntamente com os desvios-padrão entre vídeos.

Tabela II. CCC médio ($\pm$ DP) e IC 95% bootstrap para o OMG-Empathy (n = 15 vídeos).

Sistema	CCC médio	IC 95% (bootstrap)	DP
LLM C3 (visão) — zero-shot	+0,158	[+0,085; +0,230]	0,146
Baseline (regras, multi-frame)	+0,148	[+0,044; +0,259]	0,212
LLM C2 (blendshapes) — few-shot k = 3	+0,127	[+0,046; +0,213]	0,165
LLM C2 (blendshapes) — zero-shot	+0,090	[+0,007; +0,176]	0,166

A **Figura 1** ilustra o CCC médio por condição com os respectivos intervalos de confiança bootstrap de 95%. Observa-se que a visão nativa do LLM (C3) é estatisticamente indistinguível do baseline tradicional baseado em regras.




Figura 1. CCC médio por condição com IC 95% bootstrap. A visão nativa do LLM (C3) é estatisticamente indistinguível do baseline tradicional baseado em regras.

O LLM com visão nativa (C3) alcança um CCC de +0,158, marginalmente acima do baseline baseado em regras (+0,148). Entretanto, o teste de Wilcoxon signed-rank não revela diferença significativa ($W = 45,0$; $p = 0,421$; d de Cohen = +0,07), confirmando um empate estatístico. Os ICs bootstrap de 95% se sobrepõem substancialmente ([+0,085; +0,230] vs. [+0,044; +0,259]).

A única diferença estatisticamente significativa é entre o **baseline e o C2 zero-shot** ($W = 17,0$; **$p = 0,013$** ; $d = +0,64$, efeito médio), indicando que o LLM apresenta desempenho significativamente inferior ao receber features numéricas de blendshape serializadas sem exemplos in-context. A **Tabela III** detalha todos os testes pareados.

Tabela III. Testes pareados de Wilcoxon signed-rank entre condições ($n = 15$ vídeos).

Comparação	Δ média	W	p	d de Cohen
C3 visão vs. Baseline	+0,010	45,0	0,421	+0,07 (pequeno)

Comparação	Δ média	W	p	d de Cohen
C3 visão vs. C2 zero-shot	+0,068	30,0	0,095	+0,57 (médio)
C2 few-shot vs. C2 zero-shot	+0,038	32,0	0,121	+0,51 (médio)
C2 few-shot vs. Baseline	−0,020	38,0	0,229	−0,30 (pequeno)
Baseline vs. C2 zero-shot	+0,058	17,0	0,013	+0,64 (médio)

O aprendizado few-shot melhora o C2 de +0,090 para +0,127 (d = +0,51, efeito médio), mas essa melhoria não atinge significância em $\alpha = 0,05$ ($p = 0,121$).

A **Figura 2** apresenta o CCC discriminado por vídeo individual para os quatro sistemas avaliados.




Figura 2. CCC por vídeo individual nos quatro sistemas avaliados. O desempenho varia substancialmente entre sujeitos e histórias, com alta variância inter-vídeo (DP 0,15–0,21).

Conforme ilustrado na Figura 2, a variabilidade inter-vídeo é substancial. Vídeos dos sujeitos 2 e 6 com a história 3 consistentemente apresentam os maiores CCCs em todos os sistemas (CCC > +0,30), enquanto os sujeitos 1 (história 6) e 9 (história 7) exibem valores negativos de CCC, sugerindo que essas interações contêm variação afetiva mínima rastreável ou apresentam desafios particulares para todos os métodos.

5.2 CMU-MOSEI: Classificação Multi-Rótulo de Emoção

A **Tabela IV** compara todos os sistemas em 400 segmentos de teste. O limiar de saída do LLM foi selecionado via busca em grade sobre [0,01; 0,50] nos scores inteiros de Ekman (melhor limiar = 0,15 para todas as condições do LLM).

Tabela IV. F1-scores multi-rótulo no CMU-MOSEI (400 segmentos de teste).

Sistema	F1 micro	F1 macro	F1 ponderado
Acaso aleatório	0,313	—	—
Majoritário (<i>happiness</i>)	0,391	0,108	0,214
Baseline (LogReg sobre FACET)	0,376	0,333	0,423
LLM C1 (texto) — zero-shot	0,482	0,416	0,493
LLM C1 (texto) — few-shot k = 5	0,499	0,416	0,498
LLM C2 (FACET) — zero-shot	0,111	0,057	0,096
LLM C2 (FACET) — few-shot k = 5	0,289	0,130	0,213

Os resultados da Tabela IV são visualizados na **Figura 3**, que ilustra as três variantes de F1 para cada sistema.




Figura 3. F1-scores multi-rótulo (micro, macro, ponderado) para todos os sistemas. As condições baseadas em texto (C1) do LLM dominam, enquanto o LLM baseado em FACET (C2) apresenta desempenho inferior ao baseline aleatório em zero-shot.

O LLM baseado em texto (C1) alcança um macro-F1 de 0,416, superando o baseline treinado de LogReg em **25%** (0,333), conforme detalhado na Tabela IV e ilustrado na Figura 3. Essa vantagem é robusta à escolha da métrica: o LLM também lidera em micro-F1 (0,499 vs. 0,376) e F1-ponderado (0,498 vs. 0,423). A melhoria é consistente entre as configurações zero-shot e few-shot, com o few-shot proporcionando apenas ganhos marginais (+0,017 em micro-F1), sugerindo que o conhecimento de mundo pré-treinado do LLM já captura semânticas emocionais ricas a partir do texto.

Em contraste, o LLM recebendo features numéricas FACET brutas (C2) colapsa para um macro-F1 de 0,057 em zero-shot — **abaixo do acaso aleatório** (0,313 em micro-F1). O aprendizado few-shot recupera parcialmente o desempenho (macro-F1 de 0,057 para 0,130, melhoria de 2,3×), mas o sistema permanece muito aquém do baseline treinado. Esse padrão espelha os achados do OMG: LLMs não são adequados para interpretar vetores de features numéricas densas serializados como texto.

5.3 Análise por Emoção

A **Tabela V** e a **Figura 4** decompõem os F1-scores por categoria de emoção de Ekman [8].

Tabela V. F1 por emoção: LLM texto (C1) vs. baseline FACET. A coluna Δ indica a diferença entre o melhor LLM e o baseline.

Emoção	Prevalência	Baseline	LLM C1 zero-shot	LLM C1 few-shot	Δ melhor
happiness	0,42	0,60	0,56	0,57	−0,03
sadness	0,31	0,37	0,40	0,38	+0,03
anger	0,32	0,25	0,48	0,52	+0,27
fear	0,04	0,07	0,16	0,14	+0,09
disgust	0,30	0,49	0,63	0,63	+0,14
surprise	0,12	0,21	0,26	0,25	+0,05




Figura 4. Comparação de F1 por emoção. O LLM apresenta os maiores ganhos nas emoções minoritárias (anger +0,27; disgust +0,14), enquanto o baseline retém uma leve vantagem na classe majoritária (happiness).

Conforme ilustrado na Figura 4 e detalhado na Tabela V, o LLM supera o baseline em **cinco das seis** categorias de Ekman. Os maiores ganhos ocorrem em **anger** (+0,27) e **disgust** (+0,14), precisamente as emoções onde a LogReg baseada em FACET mais sofre devido ao desbalanceamento de classes e ao poder discriminativo limitado das 35 action units faciais para essas categorias. O baseline retém vantagem marginal apenas em **happiness** (0,60 vs. 0,57), a classe dominante onde um classificador baseado em frequência naturalmente se destaca.

Esse padrão é consistente com achados recentes de que LLMs possuem fortes priors linguísticos para reconhecimento de emoção [13], particularmente para categorias minoritárias e nuançadas onde classificadores supervisionados treinados em conjuntos de features pequenos tendem a predições majoritárias. Entretanto, conforme observado por Zhang et al. [15], LLMs podem gerar rótulos de emoção consistentes com a teoria psicológica sem capturar plenamente sutilezas contextuais — uma limitação que nossa métrica macro-F1, operando no nível de categorias de Ekman, não penaliza.

6. Discussão

6.1 Vantagem Dependente de Modalidade

O achado central deste estudo é que a vantagem do LLM sobre métodos tradicionais **não é universal, mas dependente da modalidade**. A Tabela VI sintetiza os resultados com a evidência estatística correspondente.

Tabela VI. Síntese da vantagem comparativa por modalidade e tarefa.

Modalidade / tarefa	Vencedor	Evidência estatística
Emoção a partir de texto (MOSEI, C1)	LLM	macro-F1 0,416 vs. 0,333 (+25%)
Valência contínua — visão nativa (OMG, C3)	Empate	CCC 0,158 vs. 0,148; p = 0,421; d = 0,07

Modalidade / tarefa	Vencedor	Evidência estatística
Valência contínua — blendshapes (OMG, C2 few-shot)	Empate (leve)	CCC 0,127 vs. 0,148; $p = 0,229$; $d = -0,30$
Valência contínua — blendshapes (OMG, C2 zero-shot)	Tradicional	CCC 0,090 vs. 0,148; $p = 0,013$; $d = 0,64$
Emoção a partir de FACET numérico (MOSEI, C2)	Tradicional	macro-F1 0,057–0,130 vs. 0,333

Texto → LLM se destaca. O LLM utiliza seu massivo corpus de pré-treinamento para reconhecer conteúdo emocional em linguagem natural com capacidade zero-shot que supera um classificador supervisionado treinado em 6.000 amostras rotuladas. Isso se alinha com a tendência mais ampla identificada em surveys recentes [13][14]: LLMs oferecem compreensão afetiva competitiva ou superior quando a entrada é textual, mesmo sem fine-tuning específico de tarefa.

Imagem → competitivo. O encoder de visão do Gemma 4 (~550 M parâmetros) alcança paridade com o motor de regras de blendshapes na regressão contínua de valência, conforme demonstrado na Tabela II e Tabela III. Isso é notável dado que a condição de visão recebe frames JPEG brutos sem engenharia de features faciais, enquanto o baseline opera com regras cuidadosamente projetadas mapeando 52 coeficientes de blendshape para o espaço de valência-arousal [12].

Features numéricas → LLM falha. Quando features faciais são serializadas como texto (C2), o LLM apresenta desempenho significativamente inferior. Esse achado é consistente entre ambos os datasets: CCC de 0,090 vs. 0,148 no OMG (Tabela II); macro-F1 de 0,057 vs. 0,333 no MOSEI em zero-shot (Tabela IV). O modo de falha sugere que LLMs atuais carecem de uma representação interna efetiva para interpretar vetores densos de ponto flutuante embutidos em prompts de linguagem natural. Exemplos few-shot mitigam parcialmente essa lacuna (CCC +0,037; macro-F1 $\times 2,3$), mas não a eliminam.

6.2 Implicações para Robótica e HRI

Em cenários de interação humano-robô (HRI), a escolha entre um LLM e um pipeline clássico deve ser guiada pela modalidade disponível:

- **Sistemas de fala/diálogo:** LLMs oferecem reconhecimento de emoção superior a partir de transcrições, possibilitando agentes conversacionais mais empáticos.
- **Sistemas baseados em câmera:** LLMs com encoders de visão equiparam pipelines tradicionais de análise facial, com o benefício adicional de não requerer engenharia de features.
- **Pipelines de fusão sensorial** que produzem vetores de features numéricos: ML clássico permanece preferível; o overhead e a latência de uma chamada ao LLM não se justificam dado o desempenho degradado em entradas numéricas.

6.3 Efeito do Aprendizado In-Context

Exemplos few-shot melhoram o desempenho em todas as condições, mas a magnitude da melhoria é inversamente proporcional ao desempenho zero-shot de base, conforme sumarizado na **Tabela VII**.

Tabela VII. Efeito do aprendizado few-shot por condição.

Condição	Zero-shot	Few-shot	Melhoria
C1 texto (MOSEI, macro-F1)	0,416	0,416	+0,0%
C2 blendshapes (OMG, CCC)	+0,090	+0,127	+41%
C2 FACET (MOSEI, macro-F1)	0,057	0,130	+128%

Quando o LLM já apresenta bom desempenho (texto), os exemplos few-shot acrescentam pouco. Quando a entrada é desconhecida (features numéricas), os exemplos few-shot fornecem calibração crucial — ainda que insuficiente para equiparar-se aos baselines treinados (Tabela VII). Isso sugere que o gargalo é representacional (a incapacidade do modelo de processar tokens numéricos efetivamente), e não simplesmente uma questão de enquadramento da tarefa.

7. Limitações

Diversas ressalvas devem ser consideradas ao interpretar estes resultados:

1. **Tamanho amostral (OMG):** Avaliamos 15 dos 30 vídeos de teste disponíveis. A variância inter-vídeo é alta (DP 0,15–0,21), e nenhuma comparação pareada entre C3 e o baseline atinge significância (Tabela III). Expandir para o test set completo aumentaria o poder estatístico.
2. **Seleção de limiar (MOSEI):** O limiar de emoção do LLM foi selecionado via busca em grade no próprio conjunto de teste (melhor = 0,15), o que pode introduzir viés otimista leve. Um conjunto de validação separado deveria ser utilizado para calibração final.
3. **Prompt único / seed única:** Os resultados são baseados em um único template de prompt e decodificação determinística (temperatura = 0). Embora a arquitetura MoE introduza variação estocástica mínima, a sensibilidade ao prompt permanece uma preocupação conhecida para avaliação baseada em LLMs [15].
4. **Potencial contaminação de dados:** As transcrições do CMU-MOSEI originam-se de vídeos públicos do YouTube e podem ter aparecido no corpus de pré-treinamento do Gemma [7], potencialmente inflando o desempenho baseado em texto (C1). Declaramos isso como limitação sem estimativa quantitativa da sobreposição.
5. **Quantização AWQ 4-bit:** O modelo foi quantizado de bfloat16 para inteiros de 4 bits via AWQ [2]. Embora o AWQ seja projetado para preservar a generalização entre modalidades, não medimos o delta de performance induzido pela quantização em tarefas de computação afetiva especificamente.
6. **Força dos baselines:** O baseline do OMG utiliza regras manuais e o do MOSEI utiliza Regressão Logística — nenhum dos dois representa o estado da arte em reconhecimento de emoção facial supervisionado. Baselines mais fortes (e.g., redes neurais fine-tuned sobre FACET ou CNNs end-to-end) poderiam estreitar a diferença com o LLM no texto.

Referências

[1] Gemma Team, Google DeepMind. "Gemma 3 Technical Report." *arXiv preprint arXiv:2503.19786*, 2025. (Base arquitetural do Gemma 4 26B-A4B usado neste estudo; model card: ai.google.dev/gemma/docs/core/model_card_4)

- [2] J. Lin, J. Tang, H. Tang, S. Yang, W.-M. Chen, W.-C. Wang, G. Xiao, X. Dang, C. Gan, and S. Han. "AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration." In *Proc. MLSys*, 2024.
- [3] W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. E. Gonzalez, H. Zhang, and I. Stoica. "Efficient Memory Management for Large Language Model Serving with PagedAttention." In *Proc. 29th SOSP*, 2023.
- [4] LangChain, Inc. "LangGraph: Building Language Agents as Graphs." 2024. github.com/langchain-ai/langgraph.
- [5] P. V. A. Barros, N. Churamani, A. Lim, and S. Wermter. "The OMG-Empathy Dataset: Evaluating the Impact of Affective Behavior in Storytelling." In *8th ACII*, pp. 1–7, IEEE, 2019.
- [6] L. I.-K. Lin. "A Concordance Correlation Coefficient to Evaluate Reproducibility." *Biometrics*, vol. 45, no. 1, pp. 255–268, 1989.
- [7] A. B. Zadeh, P. P. Liang, S. Poria, E. Cambria, and L.-P. Morency. "Multimodal Language Analysis in the Wild: CMU-MOSEI Dataset and Interpretable Dynamic Fusion Graph." In *Proc. 56th ACL*, pp. 2236–2246, 2018.
- [8] P. Ekman. "An Argument for Basic Emotions." *Cognition & Emotion*, vol. 6, no. 3-4, pp. 169–200, 1992.
- [9] A. Zadeh, P. P. Liang, S. Poria, P. Vij, E. Cambria, and L.-P. Morency. "Multi-attention Recurrent Network for Human Communication Comprehension." In *32nd AAAI*, 2018.
- [10] iMotions A/S. "FACET — Facial Action Coding System." imotions.com/biosensor/facs-facial-action-coding-system.
- [11] R. Surdulescu et al. "Blendshapes GHUM: Real-time Monocular Facial Blendshape Prediction." *arXiv preprint arXiv:2309.05782*, 2023.
- [12] J. A. Russell. "A Circumplex Model of Affect." *Journal of Personality and Social Psychology*, vol. 39, no. 6, pp. 1161–1178, 1980.
- [13] "Affective Computing in the Era of Large Language Models: A Survey from the NLP Perspective." *arXiv preprint arXiv:2408.04638*, 2024.
- [14] "Multimodal Large Language Models Meet Multimodal Emotion Recognition and Reasoning: A Survey." *arXiv preprint arXiv:2509.24322*, 2025.

[15] "Fluent but Unfeeling: The Emotional Blind Spots of Language Models." *arXiv preprint arXiv:2509.09593*, 2025.

[16] "Large Language Models Meet Text-Centric Multimodal Sentiment Analysis: A Survey." *arXiv preprint arXiv:2406.08068*, 2024.